

PROYECTO FINAL

Implementacion, Evaluacion y Optimizacion de Modelos de Machine Learning

Prediccion del rendimiento academico de estudiantes

Institucion	Universidad Tecnologica
Asignatura	Machine Learning / Ciencia de Datos
Alumno(s)	[Escribe aqui los nombres]
Docente	[Escribe aqui el nombre]
Fecha	28 de julio de 2026

Indice

1. Introduccion

2. Caso de estudio

3. Objetivos

4. Dataset utilizado

5. Justificacion de los algoritmos

6. Diseno de los modelos

7. Implementacion

8. Evaluacion

9. Optimizacion

10. Resultados

11. Evidencias

12. Conclusiones

13. Bibliografia

14. Anexos

Entregables incluidos

CSV con 200 registros, notebook de clasificacion, notebook de regresion, graficas, documento tecnico, README, guía de GitHub y archivo ZIP listo para entregar.

1. Introduccion

Las instituciones educativas generan datos que pueden aprovecharse para identificar patrones de rendimiento y ofrecer apoyo oportuno. En este proyecto se desarrolla un flujo completo de Machine Learning supervisado para estimar si un estudiante aprobará o reprobará y para predecir su calificación final.

El trabajo integra preparación de datos, selección de algoritmos, entrenamiento, evaluación con métricas especializadas, optimización mediante búsqueda de hiperparámetros, interpretación de variables y documentación reproducible. Los dos problemas se resuelven con el mismo conjunto de variables de entrada, pero con objetivos y métricas diferentes.

Alcance académico

Los 200 registros son sintéticos y anónimos. Fueron generados para demostrar el proceso de ciencia de datos sin utilizar información personal real de estudiantes.

2. Caso de estudio

La Universidad Tecnológica desea contar con un sistema inteligente que ayude a los coordinadores académicos a intervenir antes de que un alumno repruebe. La institución dispone de indicadores de rendimiento previo, asistencia, dedicación al estudio, actividad en Moodle, tareas y participación.

El proyecto responde dos preguntas centrales:

1. Clasificación: determinar si el alumno pertenece a la clase Aprueba o Reprueba.
2. Regresión: estimar la calificación final esperada en una escala de 0 a 100.

La salida del sistema puede servir como alerta temprana para tutorías, seguimiento individual y priorización de apoyos. No debe utilizarse como una decisión automática definitiva, sino como información adicional para el personal académico.

3. Objetivos

3.1 Objetivo general

Desarrollar, evaluar y optimizar un modelo de clasificación y un modelo de regresión capaces de predecir el rendimiento académico de estudiantes a partir de datos tabulares.

3.2 Objetivos específicos

- Construir un dataset consistente con aproximadamente 200 registros.
- Preparar variables de entrada y objetivos sin fuga de información.
- Dividir los datos en 80% para entrenamiento y 20% para prueba.
- Implementar modelos base interpretables con árboles de decisión.
- Evaluar clasificación con Accuracy, Precision, Recall, F1 y matriz de confusión.
- Evaluar regresión con MAE, MSE, RMSE y R2.
- Optimizar ambos modelos mediante Random Forest y GridSearchCV.
- Comparar resultados antes y después, e identificar las variables más importantes.
- Preparar una estructura lista para publicarse en GitHub.

4. Dataset utilizado

El archivo alumnos.csv contiene 200 registros y 10 columnas. La clase Aprueba aparece en 107 registros y Reprueba en 93. La calificación final promedio es 70.79.

Los valores se generaron con distribuciones realistas y relaciones controladas entre rendimiento previo, asistencia, estudio, actividad digital y entrega de tareas. Se agrego ruido aleatorio para evitar un problema perfectamente determinista y representar variaciones no observadas.

Variable	Descripcion	Tipo	Uso
Promedio	Promedio previo del estudiante	Numerica	Entrada
Parcial	Calificacion del examen parcial	Numerica	Entrada
Asistencia	Porcentaje de asistencia	Numerica	Entrada
Horas_Estudio	Horas de estudio por semana	Numerica	Entrada
Accesos_Moodle	Actividad en la plataforma virtual	Entera	Entrada
Tareas_Entregadas	Tareas entregadas de 12	Entera	Entrada
Participacion_Clase	Participacion de 0 a 10	Entera	Entrada
Calificacion_Final	Calificacion de 0 a 100	Numerica	Objetivo de regresion
Resultado	Aprueba o Reprueba	Categorica	Objetivo de clasificacion

Tabla 1. Descripcion y funcion de las variables del dataset.

Validacion	Resultado
Registros	200
Valores faltantes	0
Registros duplicados	0
Division entrenamiento/prueba	80% / 20%
Semilla aleatoria	42

Tabla 2. Controles de calidad y reproducibilidad.




Figura 1. Distribucion de clases en el conjunto de datos.




Figura 2. Correlaciones entre variables numericas.

5. Justificacion de los algoritmos

5.1 Modelo inicial: Arbol de Decision

Se selecciono un arbol de decision como modelo inicial para ambos problemas porque aprende reglas directas a partir de los datos y permite explicar de forma visual como se separan los casos. Su interpretabilidad es apropiada para presentar el procedimiento a coordinadores academicos y establecer una linea base sencilla.

La profundidad se limito a 2 para evitar que el modelo inicial memorice los datos. Esta decision produce un punto de comparacion deliberadamente simple y permite observar con claridad el efecto de la optimizacion.

5.2 Modelo optimizado: Random Forest

Random Forest combina multiples arboles entrenados con muestras y subconjuntos de variables. La agregacion reduce la variabilidad de un solo arbol y suele mejorar la capacidad de generalizacion en datos tabulares. Tambien ofrece importancias de variables para interpretar los factores con mayor influencia.

La seleccion de hiperparametros se realizo con GridSearchCV y validacion cruzada de cuatro particiones. Para clasificacion se optimizo F1; para regresion se minimizo RMSE.

6. Diseno de los modelos

Etapas	Clasificacion	Regresion
Entradas	7 variables predictoras	7 variables predictoras
Objetivo	Resultado: 0=Reprueba, 1=Aprueba	Calificacion_Final
Modelo base	DecisionTreeClassifier(max_depth=2)	DecisionTreeRegressor(max_depth=2)
Modelo optimizado	RandomForestClassifier	RandomForestRegressor
Division	80% entrenamiento / 20% prueba estratificada	80% entrenamiento / 20% prueba
Validacion	StratifiedKFold, 4 particiones	KFold, 4 particiones
Criterio de optimizacion	F1	RMSE

Tabla 3. Diseno comparativo de los dos modelos.

Prevencion de fuga de informacion

La columna Calificacion_Final no se utiliza para predecir Resultado. Incluirla haria que el modelo conociera indirectamente la respuesta, porque Resultado se determina con el umbral de

aprobacion.

7. Implementacion

La implementacion se realizo en notebooks de Jupyter compatibles con Google Colab. Cada notebook contiene texto explicativo, codigo ejecutable, salidas, tablas y graficas. El flujo aplicado fue el siguiente:

3. Importar Pandas, NumPy, Scikit-Learn y Matplotlib.
4. Leer alumnos.csv y revisar dimensiones, valores faltantes y duplicados.
5. Separar las siete variables independientes y la variable objetivo.
6. Aplicar train_test_split con una proporcion 80/20.
7. Entrenar el arbol de decision base y generar predicciones.
8. Calcular las metricas correspondientes al tipo de problema.
9. Ejecutar GridSearchCV sobre un Random Forest.
10. Evaluar el mejor estimador sobre el mismo conjunto de prueba.
11. Comparar antes y despues e interpretar importancia de variables.

7.1 Hiperparametros evaluados

Hiperparametro	Valores probados	Funcion
n_estimators	100, 200	Numero de arboles del bosque
max_depth	None, 5, 8	Profundidad maxima de cada arbol
min_samples_split	2, 4	Mínimo de casos para dividir un nodo
min_samples_leaf	1, 2	Mínimo de casos por hoja
max_features	sqrt; 1.0 en regresion	Variables candidatas por division

Tabla 4. Espacio de busqueda para la optimizacion.

8. Evaluacion

8.1 Metricas de clasificacion

- Accuracy: proporcion total de predicciones correctas.
- Precision: de los alumnos predichos como aprobados, cuantos realmente aprobaron.
- Recall: de los alumnos que aprobaron, cuantos fueron identificados por el modelo.
- F1 Score: media armonica de precision y recall.
- Matriz de confusion: muestra verdaderos positivos, verdaderos negativos y los dos tipos de error.

Metrica	Antes	Despues
Accuracy	0.700	0.825
Precision	0.636	0.769
Recall	1.000	0.952
F1 Score	0.778	0.851

Tabla 5. Metricas de clasificacion antes y despues.




Figura 3. Comparacion de metricas de clasificacion.

8.2 Metricas de regresion

- MAE: error absoluto promedio medido en puntos de calificacion.
- MSE: promedio del error al cuadrado, que penaliza mas los errores grandes.
- RMSE: raiz del MSE; se interpreta en la misma escala de la calificacion.
- R2: proporcion de variabilidad explicada por el modelo; valores mayores indican mejor ajuste.

Metrica	Antes	Despues
MAE	7.236	4.757
MSE	85.428	34.497
RMSE	9.243	5.873
R2	0.298	0.716

Tabla 6. Metricas de regresion antes y despues.




Figura 4. Reduccion del error en el modelo de regresion.

9. Optimizacion

La mejora principal consistio en cambiar de un solo arbol limitado a un conjunto de arboles y seleccionar automaticamente los hiperparametros mediante validacion cruzada. El conjunto de prueba se mantuvo separado durante la busqueda y solo se utilizo para la evaluacion final.

En clasificacion, la exactitud paso de 0.700 a 0.825. El recall optimizado fue 0.952, lo cual indica que se identifico a la gran mayoria de los alumnos que realmente aprobaron.

En regresion, el RMSE disminuyo de 9.243 a 5.873, una reduccion aproximada de 36.5%. El R2 aumento de 0.298 a 0.716.

Modelo	Mejores hiperparametros	Criterio
Random Forest Classifier	{ "max_depth": null, "max_features": "sqrt", "min_samples_leaf": 1, "min_samples_split": 4, "n_estimators": 100 }	F1
Random Forest Regressor	{ "max_depth": 8, "max_features": "sqrt", "min_samples_leaf": 1, "min_samples_split": 4, "n_estimators": 100 }	RMSE

Tabla 7. Configuraciones seleccionadas por GridSearchCV.

10. Resultados

10.1 Algoritmo con mejor desempeño

Random Forest fue el algoritmo con mejor desempeño en ambos problemas. La combinación de varios árboles captó relaciones no lineales y fue menos sensible a una sola partición de los datos que el árbol base.

10.2 Variables más importantes

En clasificación, las variables principales fueron Parcial (0.255), Promedio (0.218), Horas_Estudio (0.146).

En regresión, las variables principales fueron Parcial (0.220), Horas_Estudio (0.195), Promedio (0.194).




Figura 5. Importancia de variables en clasificación.




Figura 6. Importancia de variables en regresión.

10.3 Interpretación institucional

Los resultados sugieren que el rendimiento previo y el parcial contienen información académica directa, mientras que la asistencia, las tareas y las horas de estudio aportan evidencia conductual. Un coordinador puede usar estas variables para identificar perfiles de riesgo y recomendar tutorías, regularización o seguimiento de hábitos de estudio.

Uso responsable

Una importancia alta no demuestra causalidad. Las predicciones deben revisarse junto con contexto académico, condiciones personales y criterio profesional.

11. Evidencias



Figura 7. Captura resumen de metricas de clasificacion.




Figura 8. Matriz de confusion del modelo optimizado.

Evidencia de evaluacion - Regresion

El modelo optimizado reduce el error y explica una mayor proporcion de la variabilidad.

MAE	Antes: 7.236	Despues: 4.757
MSE	Antes: 85.428	Despues: 34.497
RMSE	Antes: 9.243	Despues: 5.873
R2	Antes: 0.298	Despues: 0.716

Figura 9. Captura resumen de metricas de regresion.




Figura 10. Valores reales y predichos por el modelo optimizado.




Figura 11. Distribucion de residuos del modelo de regresion.

12. Conclusiones

- Se construyo un dataset sintetico de 200 estudiantes con variables academicas y de participacion.
- Los dos notebooks cumplen el flujo de preparacion, entrenamiento, prediccion, evaluacion y optimizacion.
- El clasificador optimizado alcanzo Accuracy=0.825, Precision=0.769, Recall=0.952 y F1=0.851.
- El regresor optimizado obtuvo MAE=4.757, RMSE=5.873 y R2=0.716.
- Random Forest supero a los arboles base y mostro que la optimizacion de hiperparametros aporta una mejora medible.
- Las variables de rendimiento previo, parcial, asistencia y dedicacion fueron las fuentes de informacion mas relevantes.
- Para uso real se requieren mas registros, validacion externa, monitoreo de sesgos y proteccion de datos personales.

12.1 Trabajo futuro

- Incorporar historial por semestre, dificultad de materias y secuencias temporales.
- Evaluar calibracion de probabilidades y ajustar umbrales para priorizar estudiantes en riesgo.
- Comparar con Gradient Boosting y modelos lineales regularizados.
- Desarrollar un tablero para coordinadores con explicaciones por estudiante.
- Validar el modelo con datos reales autorizados y anonimizados.

13. Bibliografía

12. Scikit-learn Developers. Decision Trees. <https://scikit-learn.org/stable/modules/tree.html>
13. Scikit-learn Developers. RandomForestClassifier. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
14. Scikit-learn Developers. RandomForestRegressor. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>
15. Scikit-learn Developers. Metrics and scoring. https://scikit-learn.org/stable/modules/model_evaluation.html
16. Scikit-learn Developers. Tuning the hyper-parameters of an estimator. https://scikit-learn.org/stable/modules/grid_search.html
17. Pandas Development Team. pandas.read_csv. https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.read_csv.html
18. Matplotlib Development Team. Matplotlib documentation. <https://matplotlib.org/stable/>
19. NumPy Developers. NumPy documentation. <https://numpy.org/doc/stable/>

14. Anexos

14.1 Estructura del repositorio

```

Proyecto_MachineLearning
├── Dataset
│   ├── alumnos.csv
│   └── diccionario_datos.csv
├── Clasificacion
│   └── clasificacion.ipynb
├── Regresion
│   └── regresion.ipynb
├── Imagenes
│   └── *.png
├── Documentacion
│   ├── Reporte.pdf
│   ├── Reporte.docx
│   └── resultados_modelos.json
├── README.md
├── requirements.txt
└── GUIA_GITHUB.md
  
```

14.2 Lista de evidencias entregadas

- Documento PDF y version editable DOCX.
- CSV principal y diccionario de datos.
- Notebook de clasificacion ejecutado.
- Notebook de regresion ejecutado.
- Graficas de distribucion, correlacion, matrices de confusion, importancia, predicciones y residuos.
- Capturas resumen de las metricas antes y despues.
- README con instrucciones y resultados.
- Guia para publicar el repositorio en GitHub.

Pendiente de completar antes de entregar

Sustituye los campos de alumno(s) y docente de la portada. Después publica la carpeta en tu cuenta de GitHub y pega la URL del repositorio en la plataforma de entrega.