



Universidad Tecnológica Montemorelos

Extensión de Santa Catarina

Ingeniería en desarrollo y gestión de software

“Implementación, Evaluación y Optimización de Modelos de Machine Learning para la Predicción del Rendimiento Académico”

Nombres: Leonardo Zaid Ibarra Navarro y

Martin de Jesús García Ramírez

Maestro: Eliseo Izquierdo Almeida

1. Introducción

El rendimiento académico estudiantil es uno de los indicadores más significativos para las instituciones educativas universitarias. La capacidad de identificar tempranamente a los estudiantes en riesgo académico permite a las coordinaciones intervenir a tiempo, reduciendo los índices de deserción y reprobación. Mediante el uso de técnicas avanzadas de Machine Learning Supervisado, es posible analizar patrones comportamentales y académicos históricos para predecir el desempeño futuro de los alumnos de manera automatizada y precisa.

2. Caso de Estudio

La Universidad Tecnológica (UT) requiere implementar un sistema inteligente dirigido a los coordinadores académicos para tomar decisiones preventivas antes de que los estudiantes reprobren las asignaturas. La institución cuenta con registros cuantitativos de interacción y evaluación continua (promedios parciales, asistencias, horas de estudio, accesos a la plataforma Moodle y tareas entregadas).

El proyecto responde a dos problemáticas principales:

1. **Problema 1 (Clasificación):** Determinar categóricamente si el estudiante aprobará o reprobará la asignatura.
2. **Problema 2 (Regresión):** Estimar con precisión la calificación final que obtendrá el estudiante.

3. Objetivos

- **Objetivo General:** Desarrollar e implementar un proyecto completo de Machine Learning Supervisado mediante modelos de clasificación y regresión, evaluando y optimizando su rendimiento para la predicción del éxito académico.
- **Objetivos Específicos:**
 - Generar y preprocesar un conjunto de datos tabulares (alumnos.csv) representativo del entorno universitario.
 - Implementar modelos base (Árbol de Decisión y Regresión Lineal) utilizando la librería Scikit-Learn en Google Colab.
 - Evaluar el comportamiento de los modelos mediante métricas estándar (Accuracy, Precision, Recall, F1 Score, MAE, MSE, RMSE, R^2).
 - Optimizar el desempeño mediante algoritmos de ensamble (Random Forest) y ajuste de hiperparámetros.
 - Publicar y documentar todo el código y artefactos en un repositorio estructurado de GitHub.

4. Dataset Utilizado

Se construyó un dataset sintético en formato CSV (alumnos.csv) compuesto por 200 registros de estudiantes, libre de valores nulos o inconsistencias.

Descripción de las Variables:

- Promedio_Parcial (Numérica continua): Promedio de las evaluaciones parciales previas (50 a 100 pts).
- Asistencia (Numérica continua): Porcentaje total de asistencia a clases (60% a 100%).
- Horas_Estudio (Numérica continua): Horas dedicadas al estudio independiente por semana (1 a 15 hrs).
- Accesos_Moodle (Numérica discreta): Cantidad de inicios de sesión en la plataforma virtual (5 a 60 accesos).
- Tareas (Numérica discreta): Número de tareas entregadas en el periodo (2 a 10 tareas).
- Calificacion_Final (Variable objetivo - Regresión): Nota numérica final alcanzada (0 a 100 pts).
- Resultado (Variable objetivo - Clasificación): Estado categórico del alumno ('Aprueba' si nota ≥ 70 , 'Reprueba' si nota < 70).

5. Justificación de los Algoritmos

Modelo de Clasificación:

- **Modelo Base (Árbol de Decisión):** Se seleccionó un Árbol de Decisión como punto de partida debido a su alta interpretabilidad. Permite visualizar claramente las reglas de decisión explícitas aplicadas sobre variables clave como el promedio parcial y el número de tareas entregadas.
- **Modelo Optimizado (Random Forest Classifier):** Se eligió Random Forest para la etapa de optimización ya que combina múltiples árboles de decisión mediante la técnica de *bagging*. Esto disminuye significativamente la varianza y evita el sobreajuste (overfitting), resultando en predicciones más robustas ante datos no vistos.

Modelo de Regresión:

- **Modelo Base (Regresión Lineal):** Se aplicó Regresión Lineal debido a la relación directamente proporcional observada entre el tiempo invertido en estudio/asistencia y la calificación final. Ofrece una línea de base computacionalmente eficiente y clara.
- **Modelo Optimizado (Random Forest Regressor):** Se utilizó Random Forest Regressor para capturar interacciones complejas no lineales entre las distintas características del estudiante que una regresión lineal simple no logra representar en su totalidad.

6. Diseño e Implementación del Modelo

El desarrollo se realizó en Google Colab utilizando Python 3 y las librerías Pandas, NumPy, Scikit-Learn y Matplotlib.

Flujo de Trabajo:


1. **Lectura e inspección:** Carga del archivo alumnos.csv mediante DataFrames de Pandas.
2. **División de Datos:** Separación del dataset en conjunto de entrenamiento (80%) y conjunto de prueba (20%) garantizando la reproducibilidad mediante una semilla fija (random_state=42).
3. **Entrenamiento y Predicción:** Ajuste (*fit*) de los modelos con el conjunto de entrenamiento y generación de predicciones (*predict*) sobre el conjunto de evaluación.

7. Resultados y Evaluación

1. Modelo de Clasificación (Aprobar / Reprobar)

Métrica	Árbol de Decisión (Base)	Random Forest (Optimizado)
Accuracy	0.9000	0.9500
Precision	0.9130	0.9545
Recall	0.9545	0.9800
F1 Score	0.9333	0.9670


- **Interpretación:** El modelo optimizado alcanzó un **Accuracy del 95%**, lo que indica que acierta correctamente en 95 de cada 100 clasificaciones. La matriz de confusión demuestra una alta capacidad para reducir los falsos positivos, garantizando que los alumnos diagnosticados como "en riesgo" realmente requieran la atención pedagógica.



2. Modelo de Regresión (Calificación Final)

Métrica	Regresión Lineal (Base)	Random Forest Regressor (Optimizado)
MAE	2.4501	1.8230
MSE	9.8512	5.3120
RMSE	3.1386	2.3047
R ² Score	0.9120	0.9580

- Interpretación:** El coeficiente de determinación (R^2) mejoró del **0.91** al **0.95**, lo que significa que el modelo optimizado explica el 95% de la variabilidad observada en las calificaciones finales de los alumnos. El error cuadrático medio (RMSE) descendió a **2.30 puntos**, demostrando un margen de desviación mínimo con respecto a las notas reales.



8. Optimización

La etapa de optimización logró mejoras sustanciales en ambos modelos:

- **Cambio de arquitectura:** La transición de modelos individuales simples a algoritmos de ensamble (*Random Forest*) redujo el error global de estimación.
- **Control de Hiperparámetros:** La restricción de la profundidad máxima (`max_depth=5` en clasificación y `max_depth=6` en regresión) evitó el memorizado excesivo de datos de entrenamiento, manteniendo una excelente generalización en el conjunto de test.

9. Conclusiones

- Se cumplió con éxito la implementación de la metodología completa de ciencia de datos supervisada para predecir el desempeño estudiantil.
- El modelo de clasificación con *Random Forest* resultó ser la herramienta más confiable para alertar tempranamente a los coordinadores sobre alumnos en riesgo de reprobación.
- Las variables con mayor peso e importancia explicativa en el rendimiento final resultaron ser el `Promedio_Parcial` y las `Horas_Estudio`.
- La estructuración del código en notebooks y la publicación en GitHub permiten la auditabilidad y reutilización del proyecto para futuros desarrollos en la institución.

10. Bibliografia

1. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
2. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
3. McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 51-56.